

Relazione Progetto: File System Statistics (FSStat)

Programmazione Concorrente e Distribuita

Alessandro Martini, Alessandro Torelli

Anno Accademico 2025/2026

Sommario

Il presente documento descrive la progettazione e l'implementazione della libreria **FSStatLib**, sviluppata in Java 25. L'obiettivo del progetto è analizzare un albero di directory del file system, calcolando il numero totale di file e la loro distribuzione in fasce di dimensione. L'elaborazione è stata parallelizzata utilizzando tre metodi e tecnologie differenti: i Virtual Threads, programmazione asincrona basata su event loop, e la programmazione reattiva con RX.

Indice

1	Introduzione e Requisiti	2
2	Analisi del Problema e Scelte Concorrenti	2
2.1	Approccio con i Virtual Threads	3
2.2	Approccio Asincrono basato su Event Loop	4
2.3	Approccio Reattivo con RX	4
3	Architettura e Design	4
3.1	Design dell'implementazione Virtual Threads	4
3.2	Design dell'implementazione Event Loop	6
3.3	Design dell'implementazione RX	6
4	Risultati e Osservazioni	6

1 Introduzione e Requisiti

Obiettivo

L'obiettivo è la realizzazione della libreria `FSStatLib`, che espone un metodo asincrono `getFSReport` per l'analisi statistica delle dimensioni dei file contenuti in un albero di directory del file system. Dato un percorso radice `D`, il metodo calcola e restituisce in modo asincrono un report `R` contenente:

- il **numero totale di file** presenti in `D`, incluse ricorsivamente tutte le sottodirectory;
- la **distribuzione delle dimensioni** dei file: dato un valore massimo di dimensione `MaxFS` e un numero di bande `NB`, il range `[0, MaxFS]` viene suddiviso in `NB` intervalli di ampiezza uniforme; per ciascun intervallo viene contato il numero di file la cui dimensione vi rientra. Viene inoltre conteggiata separatamente la quantità di file con dimensione superiore a `MaxFS`. Il report include quindi complessivamente `NB + 1` contatori.

I parametri `D`, `MaxFS` e `NB` sono forniti dal chiamante come argomenti del metodo.

Versioni implementate

Il progetto è stato declinato in **tre versioni indipendenti**, ciascuna aderente a una specifica disciplina di programmazione concorrente discussa durante il corso:

1. **Virtual Threads** (Java): paradigma *thread-per-task* con Virtual Thread leggeri gestiti dalla JVM.
2. **Programmazione asincrona basata su Event Loop**: composizione di operazioni non bloccanti tramite `CompletableFuture` e callback.
3. **Programmazione reattiva con RX**: modellazione del file system traversal come stream di eventi, elaborato tramite operatori funzionali (RxJava).

Un vincolo di progetto esplicito impone che le tre versioni siano sviluppate in modo **indipendente**, senza generalizzare o riutilizzare codice tra di esse qualora ciò compromettesse la purezza della disciplina di programmazione propria di ciascun approccio.

Requisito opzionale

Il progetto prevede un requisito opzionale `[*]`, obbligatorio per il conseguimento della lode, che estende la libreria con funzionalità interattive:

- possibilità di **interrompere** la generazione del report in qualsiasi momento;
- **aggiornamenti dinamici** delle statistiche durante la computazione, visualizzabili in tempo reale.

A supporto di queste funzionalità è prevista una **GUI minimale**, dotata di controlli per avviare e interrompere la scansione e di un'area di visualizzazione per il monitoraggio progressivo del report.

2 Analisi del Problema e Scelte Concorrenti

L'attraversamento ricorsivo di un file system e l'interrogazione delle proprietà dei file sono tipiche operazioni legate all'I/O. In questi scenari di I/O-bound, l'uso intensivo dei classici thread di piattaforma presenta gravi limiti di scalabilità. Per esplorare soluzioni diverse a questo problema di concorrenza, il progetto è stato declinato in tre paradigmi distinti.

2.1 Approccio con i Virtual Threads

I Virtual Threads, introdotti stabilmente in Java 21 (JEP 444), sono thread *user-mode* gestiti dalla JVM anziché dal sistema operativo. Rispetto ai *platform thread*, il loro overhead di creazione e il consumo di memoria sono trascurabili, il che li rende adatti a un modello *Thread-per-task*: è possibile istanziarne decine di migliaia senza incorrere in `OutOfMemoryError` né in degrado delle prestazioni.

Questa caratteristica si adatta in modo naturale all'attraversamento ricorsivo di un albero di directory: la struttura del file system è intrinsecamente ramificata e imprevedibile, e ogni nodo (directory) richiede operazioni di I/O bloccanti a latenza variabile (apertura dello stream, lettura degli attributi dei file con `Files.size()`). Assegnare un Virtual Thread a ciascun nodo permette di sfruttare appieno la concorrenza senza dover dimensionare a priori un pool.

Struttura dell'implementazione. Il punto di ingresso pubblico è il metodo `getFSReport()`, che restituisce una `CompletableFuture<FSReport>` per offrire un'interfaccia non bloccante al chiamante (CLI o GUI). Internamente, la computazione reale viene avviata tramite `CompletableFuture.supplyAsync()` che esegue il corpo su un Virtual Thread. All'interno di questo contesto viene creato un `ExecutorService` dedicato tramite `Executors.newVirtualThreadPerTaskExecutor()`, racchiuso in un blocco `try-with-resources`:

```
1 try (var executor = Executors.newVirtualThreadPerTaskExecutor()) {
2     Path rootPath = Paths.get(directoryPath);
3     return processDirectory(rootPath, maxFS, nb, executor).get();
4 }
```

La chiusura automatica dell'executor al termine del blocco `try` ha una semantica cruciale: `ExecutorService.close()` invoca `shutdown()` seguito da `awaitTermination()`, garantendo che nessun task figlio venga abbandonato prima che il risultato finale sia disponibile. Questo meccanismo funge da *barriera di sincronizzazione* implicita su tutto l'albero dei task.

Ricorsione concorrente e Map-Reduce. Il metodo `processDirectory()` incarna il pattern *divide et impera*: per ogni nodo dell'albero viene sottomesso all'executor un nuovo task (e quindi un nuovo Virtual Thread). All'interno del task, si itera sul contenuto della directory tramite `Files.newDirectoryStream()`:

- Per ogni **file regolare**: si invoca `Files.size()` (operazione I/O bloccante) e si aggiorna un oggetto `FSReport locale` al Virtual Thread corrente.
- Per ogni **sottodirectory**: si sottomette ricorsivamente un nuovo task all'executor, raccogliendo il `Future<FSReport>` restituito in una lista di *subTask*.

Terminata la scansione della directory corrente, il Virtual Thread chiama `task.get()` su ciascun *subTask* per attenderne il completamento e fondere i risultati parziali nel report locale tramite il metodo `FSReport.merge()`:

```
1 for (Future<FSReport> task : subTasks) {
2     localReport.merge(task.get());
3 }
```

Questa fase di riduzione segue un pattern *Map-Reduce*: la fase di *map* distribuisce il lavoro di scansione su Virtual Thread indipendenti, mentre la fase di *reduce* aggrega i report parziali bottom-up lungo l'albero, propagando i risultati verso il nodo radice.

Assenza di contesa e gestione dell'I/O bloccante. Una proprietà rilevante di questo design è la completa assenza di stato condiviso mutabile tra Virtual Thread concorrenti: ogni task opera esclusivamente sul proprio `FSReport` locale. La fusione dei risultati (`merge`) avviene sempre in modo sequenziale nel Virtual Thread padre, dopo che i figli sono terminati. Ne consegue che non è necessario alcun meccanismo di sincronizzazione esplicito (né `synchronized` né `ReentrantLock`) per proteggere il report.

Quando un Virtual Thread si blocca su un'operazione di I/O — ad esempio `Files.size()` o `task.get()` in attesa di un risultato non ancora disponibile — la JVM effettua automaticamente l'*unmount* del Virtual Thread dal *carrier thread* (il platform thread sottostante), che viene immediatamente liberato per eseguire un altro Virtual Thread pronto. Questo meccanismo permette al ridotto pool di carrier thread (tipicamente uguale al numero di core fisici) di servire migliaia di Virtual Thread concorrenti, eliminando il costo del context switch a livello di sistema operativo.

2.2 Approccio Asincrono basato su Event Loop

Il secondo paradigma adottato si basa sull'Event Loop (tipico di ecosistemi come Node.js o framework Java come Vert.x). In questo modello, un numero limitato di thread (spesso coincidente con il numero di core della CPU) esegue un ciclo continuo di dispacciamento degli eventi. Per non bloccare mai il thread dell'Event Loop, l'esplorazione del file system viene effettuata tramite API non bloccanti (NIO.2) e l'esecuzione prosegue tramite *callback* o concatenazione di `CompletableFuture`. Il carico di lavoro viene quindi frammentato in piccoli task asincroni che si risvegliano solo quando il dato (es. la dimensione del file) è pronto dal disco, garantendo alta concorrenza senza il sovraccarico del context switch tra migliaia di thread fisici.

2.3 Approccio Reattivo con RX

La terza tecnologia utilizza la Programmazione Reattiva (es. RxJava), un paradigma orientato ai flussi di dati (Data Streams) e alla propagazione dei cambiamenti. L'attraversamento del file system è stato modellato come uno stream asincrono di eventi (file trovati o directory aperte) emessi da un *Publisher / Observable*. L'approccio reattivo ha permesso di operare in modo puramente dichiarativo: attraverso operatori funzionali (`map`, `flatMap`, `filter`, `scan`) gli eventi vengono trasformati e aggregati al volo per costruire il report. Questo approccio è intrinsecamente non bloccante e facilita enormemente la gestione degli aggiornamenti in tempo reale per la GUI.

3 Architettura e Design

Il progetto è suddiviso seguendo il principio di Separazione delle Responsabilità (Separation of Concerns). Oltre al livello dell'interfaccia (CLI e GUI), la logica di dominio (il package `lib`) è stata strutturata per accomodare le tre diverse implementazioni tramite un'interfaccia comune, permettendo al chiamante di scegliere il motore di concorrenza preferito.

3.1 Design dell'implementazione Virtual Threads

L'implementazione con Virtual Threads è articolata in due classi principali nel package `it.unibo.fsstat.lib`: `FSReport`, che modella il risultato della computazione, e `FSStatLib`, che ne orchestra l'esecuzione concorrente. La CLI (`Main`) interagisce esclusivamente con l'interfaccia pubblica di `FSStatLib`, rimanendo ignara del paradigma di concorrenza sottostante.

Il modello dati: FSReport. FSReport è un *value object* che incapsula tre informazioni: il conteggio totale dei file (`totalFiles`), i parametri di classificazione (`maxFS` e `nb`), e un array `distribution` di dimensione `nb + 1`. Le prime `nb` celle corrispondono alle bande di dimensione nell'intervallo `[0, maxFS]`, mentre la cella di indice `nb` raccoglie i file che superano `maxFS`.

La classificazione di un singolo file avviene nel metodo `addFile(long size)`, che calcola l'indice di banda tramite divisione intera:

```
1 double step = (double) maxFS / nb;
2 int bandIndex = (int) (size / step);
3 if (bandIndex == nb) bandIndex = nb - 1; // Caso limite: size == maxFS
```

Il metodo `merge(FSReport other)` somma componente per componente i due array `distribution` e accumula i conteggi di `totalFiles`. Questa operazione è la chiave del pattern Map-Reduce: è associativa e non richiede alcuna sincronizzazione perché viene sempre invocata in modo sequenziale dal Virtual Thread padre dopo che i figli sono terminati.

La libreria: FSStatLib. L'interfaccia pubblica espone un unico metodo:

```
1 public CompletableFuture<FSReport> getFSReport(
2     String directoryPath, long maxFS, int nb)
```

La restituzione di una `CompletableFuture` disaccoppia il chiamante dalla concorrenza interna: la CLI può concatenare callback (`thenAccept`) oppure attendere sincronamente con `join()`, senza dover conoscere né i Virtual Thread né l'executor sottostante.

Internamente, `getFSReport` avvia la computazione tramite `CompletableFuture.supplyAsync()`, che esegue il corpo su un thread del `ForkJoinPool` comune. Da questo contesto viene creato l'executor dedicato ai Virtual Thread:

```
1 try (var executor = Executors.newVirtualThreadPerTaskExecutor()) {
2     Path rootPath = Paths.get(directoryPath);
3     return processDirectory(rootPath, maxFS, nb, executor).get();
4 }
```

Il blocco `try-with-resources` ha una funzione di lifecycle management precisa: alla sua uscita, `ExecutorService.close()` invoca `shutdown()` e `awaitTermination()`, assicurando che tutti i Virtual Thread lanciati ricorsivamente abbiano completato la propria esecuzione prima che il risultato venga restituito alla `CompletableFuture`.

Il flusso ricorsivo: processDirectory. `processDirectory` è il cuore dell'algoritmo. Ogni sua invocazione sottomette all'executor un nuovo task — e quindi un nuovo Virtual Thread — incaricato di elaborare una singola directory. Il flusso interno al task segue tre fasi:

1. **Scansione locale:** si itera sul contenuto della directory tramite `Files.newDirectoryStream()`. Per ogni file regolare, `Files.size()` legge la dimensione dal disco (operazione I/O bloccante) e la classifica nel `FSReport` locale al thread. Per ogni sottodirectory, si invoca ricorsivamente `processDirectory`, raccogliendo il `Future<FSReport>` restituito in una lista (`subTasks`).
2. **Riduzione (join):** terminata la scansione, il Virtual Thread chiama `task.get()` su ciascun elemento di `subTasks`. Se il task figlio non è ancora completato, il Virtual Thread si sospende — effettuando l'*unmount* dal carrier thread — e si risveglia non appena il risultato è disponibile. I report parziali vengono fusi nel report locale tramite `merge()`.
3. **Restituzione:** il report locale, ora completo di tutti i contributi dei sottoalberi, viene restituito come valore del `Callable` sottomesso all'executor.

La struttura risultante è un albero di Virtual Thread isomorfo all'albero delle directory: ogni nodo dell'albero FS corrisponde a un task concorrente, e la riduzione avviene bottom-up per propagazione dei `Future`.

Gestione degli errori. Gli errori di accesso al file system (directory protette, symlink non risolvibili) vengono catturati localmente da un blocco `catch (IOException e)` all'interno di ciascun task: la directory inaccessibile viene saltata con un messaggio su `stderr`, mentre la computazione prosegue sui nodi raggiungibili. Eventuali eccezioni non gestite che sfuggono al task vengono incapsulate in una `CompletionException` e propagate al chiamante tramite la `CompletableFuture`, che entra nello stato *exceptionally completed* e può essere intercettata con `.exceptionally()`.

Integrazione con la CLI. In `Main`, il chiamante configura i tre parametri della scansione (`directoryPath`, `maxFS`, `nb`) e concatena alla `CompletableFuture` una callback `thenAccept` per la stampa del report. La chiamata `.join()` finale blocca il thread principale fino al completamento, evitando che il programma termini prima che la computazione asincrona sia conclusa. La formattazione del report calcola le etichette delle bande moltiplicando l'indice per `bandSize` = `maxFS / nb`, producendo intervalli del tipo `[i·bandSize, (i+1)·bandSize]`.

3.2 Design dell'implementazione Event Loop

L'architettura in questo caso sfrutta pesantemente le chiusure (closures) e il concatenamento asincrono. L'esplorazione utilizza metodi ricorsivi che restituiscono `CompletableFuture`, elaborati su un pool ristretto (`ForkJoinPool.commonPool` o un `executor custom`). A differenza dei Virtual Threads, lo stato condiviso per il report può essere gestito spesso senza lock pesanti, incapsulando gli aggiornamenti direttamente nei thread del loop o riducendo i risultati alla fine della catena (*Map-Reduce* puramente funzionale). Il meccanismo di stop si basa sull'interruzione della propagazione delle callback.

3.3 Design dell'implementazione RX

Il design reattivo stravolge l'architettura passando dalla "richiesta di dati" (pull) alla "reazione agli eventi" (push). La libreria espone un `Flowable<FSReport>` o `Observable<FSReport>`.

- **Aggiornamenti Dinamici:** La GUI si limita a effettuare una `subscribe()` sullo stream, ricevendo un nuovo snapshot del report ogniqualvolta la pipeline reattiva emette un aggiornamento.
- **Cancellazione:** Per fermare il task è sufficiente invocare il metodo `dispose()` (o disiscriversi dallo stream); il framework RX propaga istantaneamente e in modo automatico il segnale di interruzione alla sorgente (l'esploratore delle directory), chiudendo pulitamente le risorse aperte.

4 Risultati e Osservazioni

Dai test effettuati localmente, l'overhead della creazione di migliaia di Virtual Threads è risultato impercettibile, permettendo all'applicazione di consumare una frazione della RAM che sarebbe stata necessaria usando un pool cached di platform threads. Il sistema è risultato stabile, senza mai incorrere in `OutOfMemoryError`, confermando le tesi sulla scalabilità di questo nuovo paradigma su workload I/O-bound.